Оптимизация выученной награды в последовательных рекомендациях

GPT-2, пятишаговый REINFORCE и проверка более сильной модели отклика

Итоговая работа по задаче 2 / Yambda 50M / Октябрь 2026

Аннотация. Исследуем, улучшает ли RL последовательные рекомендации, если награду задаёт обученная модель отклика. В первом цикле обучены GPT-2, четыре нейронные reward model и варианты REINFORCE с пятью наградами. На 266 активных пользователях рост предсказанной награды не дал подтверждённого прироста NDCG. Штраф за вымышленную историю также не помог: $\Delta = -0.000037$, 95% user-cluster CI $[-0.000571; +0.000497]$. Во втором цикле усилили модель отклика и supervised baseline, затем зарезервировали другую когорту. На 637 активных пользователях copy-адаптер с CE повысил NDCG на 28.5% относительно frozen GPT-2; MSE новой reward model составила 0,0598 против 0,1844 у прежней сети на тех же запросах. Тем не менее joint CE+reward с допуском по согласию моделей уступил продолжению CE: $\Delta = -0.000096$, CI $[-0.000162; -0.000037]$. Объясняем различие между точностью прогноза отклика и полезностью градиента для выбора действия. Обе когорты относятся к одному периоду; это не независимая репликация на будущей неделе.

1 Задача и исследовательский вклад

Последовательная модель учится предсказывать следующий трек в логе. RL позволяет сменить цель, например на долю прослушивания или дальнейшую активность. Но отклик на новый выбор неизвестен: оптимизатор может улучшать прогноз reward model (RM), используя её ошибки. При генерации нескольких треков возникает ещё одна проблема: рекомендация добавляется в историю, хотя пользователь мог её не слушать.

Проверены две конкретные идеи. Первая штрафует изменение RM между реальной и дополненной историей. Вторая допускает reward-обновление, только когда три RM согласны о направлении предпочтения между ветвями генерации и копирования. Обе идеи получили отрицательный основной результат. Отдельно получены улучшенный supervised baseline и существенно более точная RM; их вклад не приписывается RL.

Работы о GPTRec [1] и session-level REINFORCE [2] показывают, как переносить RL в рекомендации. Мы не воспроизводим их промышленный масштаб, off-policy correction или online-эффект. Ансамбли RM [3], copy-механизмы [4, 5] и совместный NLL+RL [6] — известные подходы. Наш вклад состоит в двух явно заданных модификациях, их контролируемой проверке и анализе неудачи. Заявления мирового приоритета или общей гарантии нет.

2 Данные и протокол оценки

Использована pinned таблица `listens` Yambda flat/50m: 46 467 212 строк,9238 UID, revision `dd6f3a19eef5`.... Поля: пользователь, item, timestamp, organic flag, доля прослушивания и длительность. Время анонимизировано, сутки равны 86 400 секундам. Выбираются пользователи, сохраняются *все* исходные строки их историй.

Цикл A. После исключения UID прежних исследований выбраны 1200 пользователей, seed 718281; сохранены 5 736 029 строк. Независимая перестановка делит UID на development 800 и external 400. Обучение — до day 270; search — days 280–286 только development UID; test — days 293–298 только external UID. Ранние истории external UID участвуют в train; их поздние метки не выбирают настройки. Получены 2770 запросов 266 активных пользователей.

Цикл B. После открытия A исправлялись выявленные ограничения на прежнем development. До новых fits выделены 1000 других UID, seed 161803, не пересекающихся с A и прежними когортами; сохранены 5 130 518 строк. Эти UID целиком исключены из обучения. Test-период тот же; получены 6393 запросов 637 активных пользователей. Новая user-когорта даёт внешнюю проверку настроек, но не заменяет проверку на другом периоде или сервисе.

Запрос — первые до 4 неорганических событий с уникальным timestamp за user-day. Нет отбора по completion. История строго раньше запроса; одновременные события не образуют искусственно упорядоченных transitions. Это оценка next logged listen, а не всех показов или удовлетворённости.

Для каждого сравнения методы имеют общий train-only каталог и одинаковые запросы. Будущий target не добавляется в кандидаты. B A каталог — 16 384 частых трека;47,4% целей вне словаря остаются промахами. B B общий каталог — 270 376 исторических items; он покрывает 80,7% целей, head GPT-2 — 48,6%, достижимая поддержка head+copy — 49,9%. Остальные цели тоже дают 0. Отдельный список misses не удаляется.

NDCG/Recall/MAP@10 для одного target сначала усредняются по model seeds 17/42/73, затем по запросам пользователя и пользователям. Для разностей используется парный bootstrap 3000 user clusters. RM MSE усредняется по событиям; resampling сохраняет кластеры и event weighting. Основной контраст в каждом цикле зафиксирован до его test. Остальные интервалы описательные, без заявления контроля семейной ошибки. CI условны на данных и fits и не покрывают полный риск обучения.

3 GPT-2 и пятишаговая RL-донастройка

GPT-2 обучается с нуля на item IDs: learned token/position embeddings, 3 pre-LN causal blocks, width 128,4 heads, GELU, MLP expansion4, final LayerNorm и tied input/output weights;2,70млн параметров. Контекст 64,

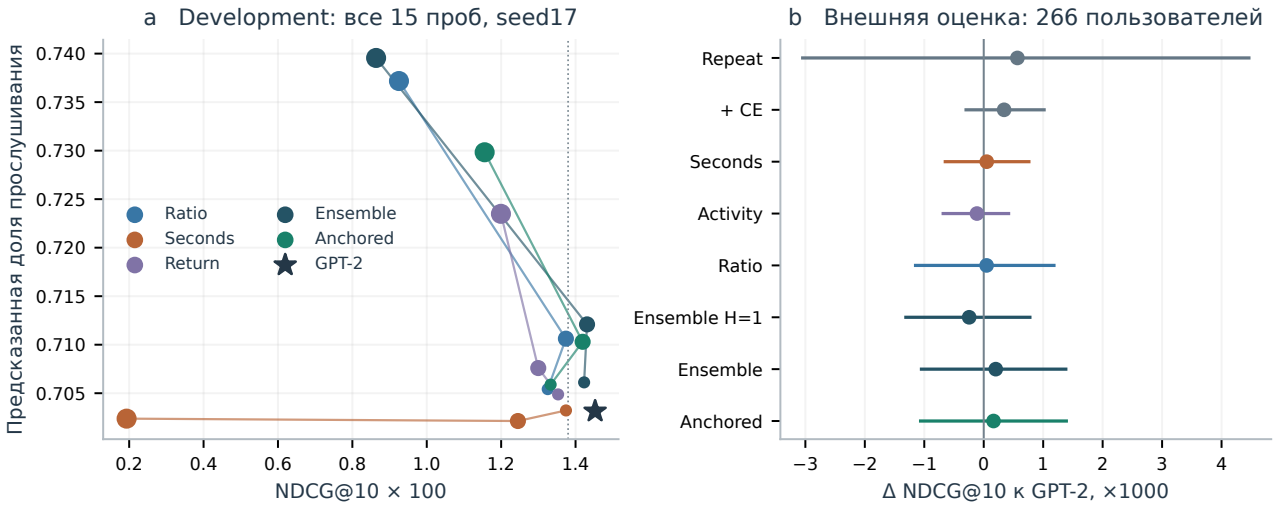


Рис. 1. Цикл A: полный development search и внешние разности с GPT-2. Вертикальная ось search показывает ratio RM также для других rewards; размер точки растёт при уменьшении KL-штрафа; пунктир — правило 95% SFT. У выбранных RL-вариантов CI к SFT включают 0. Development используется для выбора, а не как подтверждающий результат.

полная softmax по head-каталогу, редкие ID — UNK. Текстовые pretrained weights не используются.

AdamW: lr= $3 \cdot 10^{-4}$, decay 0,01, batch 64, warmup 300 и cosine. Пилот 1500 updates дал слабый baseline; до test бюджет увеличен до 12 000. На development выбран checkpoint 3000, NDCG 0,01453; дальнейшее снижение train CE не улучшило ranking. Поправка и полная траектория опубликованы. Seeds 42/73 наследуют выбранное число updates. Контроли: popularity, repeat, сглаженный Markov и ещё 120 updates CE.

Нейронная RM имеет отдельные item embeddings, mean/last history pooling, взаимодействие с кандидатом и MLP с train-only длительностью. Два sigmoid head предсказывают completion $y = \text{clip}(\texttt{played_ratio_pct}/100,0,1)$ и событие в $[t + 1h, t + 24h)$. Последнее называем Activity: оно включает продолжающееся потребление, а не только возврат после ухода. RM обучается на 855 792 реально наблюдавшихся nonorganic actions до day 269, чтобы label horizon заканчивался внутри train;800 updates, batch 512, $\text{lr}10^{-3}$, BCE. Непрослушанные кандидаты не получают фиктивный нулевой reward. Три seeds образуют ансамбль; четвёртая audit RM не оптимизируется, но при тех же данных и архитектуре не является oracle.

3.1 Награды и контроль вымышленной истории

Пусть m и s — среднее и population std ratio трёх RM. Проверены Ratio (одна RM), Seconds ($\hat{y}\min(d, 600)/600$), Activity ($0{,}5\hat{y} + 0{,}5\hat{p}_{24}$), Ensemble и предложенный Anchored:

$$r_E(h_t, a) = m(h_t, a) - 0{,}5s(h_t, a), \quad (1)$$

$$r_A(h_t, a) = r_E(h_t, a) - |m(h_t, a) - m(h_0, a)|. \quad (2)$$

Начальная h_0 реальна, h_t содержит собственные generated IDs. Anchored не позволяет бесплатно получить весь рост RM только за счёт смены контекста. Он может подавлять полезную адаптацию; std ансамбля не считается калиброванной неопределённостью.

REINFORCE работает on-policy в выученном surrogate, не в сервисе. Из реального train prefix сэмплируются 5 действий; после каждого ID добавляется в контекст без выдуманного playback outcome. С frozen SFT π_0 определены

$$\tilde{r}_t = r_t - \beta \log \frac{\pi_\theta(a_t|h_t)}{\pi_0(a_t|h_t)}, \quad (3)$$

$$G_t = \sum_{j=t}^{H-1} \gamma^{j-t} \tilde{r}_j. \quad (4)$$

Градиент использует $\gamma^t(G_t - b_t)\nabla \log \pi_\theta$; b_t — средний return остальных независимых trajectories batch. Actor dropout выключен; $\text{lr}5 \cdot 10^{-5}$, $\gamma = 0{,}9$, batch 96,120 updates, grad clip 1.

На search проверены 15 точек:5 rewards и $\beta \in \{0{,}02; 0{,}1; 0{,}5\}$. В семье выбирается максимальная predicted ratio при NDCG не ниже 95% SFT. Это правило отбора, не non-inferiority test. Выбраны$\beta = 0{,}1$ для Ratio/Ensemble/Anchored и 0,5 для Seconds/Activity. Primary A — Anchored−Ensemble при одинаковом$\beta = 0{,}1$ и H5. H1-контроль имеет те же updates, но меньше sampled actions.

Таблица 1. Внешний test A: 266 активных UID, 2770 запросов. Это среднее трёх отдельных policy fits, не ансамбль политик.

Метод	NDCG@10	Recall@10	MAP@10
Popularity	0.001982	0.004858	0.001112
Markov	0.006382	0.011533	0.004849
Repeat	0.011533	0.018675	0.009383
GPT-2	0.010967	0.021340	0.007943
+ CE	0.011309	0.021894	0.008201
Ratio	0.011015	0.020923	0.008073
Seconds	0.011017	0.021537	0.007967
Activity	0.010853	0.020633	0.007971
Ensemble H1	0.010722	0.021151	0.007666
Ensemble H5	0.011169	0.021670	0.008038
Anchored H5	0.011132	0.020675	0.008280

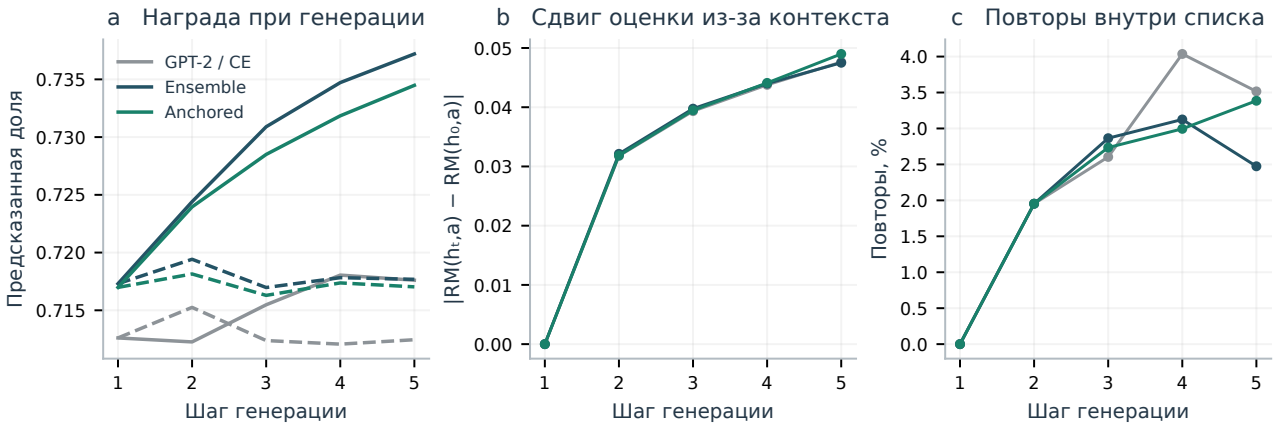


Рис. 2. Цикл A: связанные по RNG пятишаговые rollouts 256 пользователей. Сплошные линии — дополнение истории; пунктир в панели a — замороженная история. Собственные рекомендации повышают RM сильнее при обновлении контекста. Это описательный аудит, не simulator oracle.

3.2 Результат A и поведение на пяти шагах

Ensemble повысил top1 proxy completion с 0,7143 до 0,7242, но NDCG улучшилась лишь на 0,000202, CI$[-0{,}001047; 0{,}001380]$. Primary Anchored−Ensemble: -0.000037, CI$[-0.000571; +0.000497]$. Ни выигрыш контекстного штрафа, ни прирост выбранных RL к SFT не подтверждены.

На development Seconds при слабом KL($\beta = 0{,}02$) увеличил длительность до 390c и занял одним треком 51,3% top1; NDCG упала до 0,00193. По правилу такая точка не выбрана. У выбранных test-политик доминирующий top1 занимает около 1–2% запросов. Ratio сократил длительность с 192 до 182c, Seconds увеличил её примерно до 199c. Награда меняет состав выдачи, но сама по себе не гарантирует релевантность.

RM A слаба: ratio MSE ансамбля 0,1798 против 0,1806 у константы, надёжный выигрыш не установлен. Замена истории чужим ранее доступным prefix повышает MSE до 0,2056. Activity AUC 0,568, Brier 0,1379 хуже константы 0,1359. Сигнал активности не подтверждает улучшение retention.

В coupled rollout первый action совпадает при evolving/frozen history. У Ensemble средняя proxy растёт примерно 0,717→0,737 при дополнении истории и остаётся около 0,718 на шаге 5 при замороженной истории. Anchored не устранил сдвиг (рис.2). Реальных отзывов на эти новые действия нет. На teacher-forced реальных продолжениях ошибка RM выше; сравнение зависит и от отбора первых запросов и доступных шагов.

4 Второй цикл: усиление baseline и RM

Открытый test A больше не используется для выбора настроек. Разрабатываем B на прежнем development, затем один раз открываем другую заранее выделенную когорту. Frozen decoder и его 3 seeds сохраняются.

4.1 Обучаемая смесь с историей

Для head-распределения GPT-2 p_0 вводится

$$p_\theta(a|h) = (1 - g_\theta(h))p_0(a|h) + g_\theta(h) \sum_{j:h_j=a} c_\theta(j|h). \quad (5)$$

Gate — sigmoid от 13 признаков реального prefix и bias. Copy softmax имеет recency decay и вес прошлого completion. Масса повторных позиций суммируется. Обучаются 16 параметров адаптера, а не весь transformer. Tail вне последних 64 событий недостижим: расширение поддержки ограничено и не решает весь OOV.

CE-адаптер: до 40 случайных train contexts/user из days 240–269, batch 256, Adam lr0,01, checkpoint 300/600/1200 выбирается на development seed 17. Выбраны 1200 updates; другие seeds наследуют этот бюджет. Fixed смесь 50/50 и repeat с head/full каталогом — отдельные контроли.

4.2 Более точная RM и допуск reward

Новая RM — ансамбль 3 CatBoostRegressor:13 признаков состояния (прошлые completion, пропуски, длина истории, время) и 7 признаков кандидата (статистики item, длительность, повтор и давность). Item aggregates фиксируются до day 200; train — days 200–259, calibration — 260–269. До 150/30 примеров на UID; сырая история сохранена. Из глубин 4/6 и до 400 деревьев выбрана глубина 6 только по calibration MSE. Past outcomes считаются доступными по timestamp лога; задержки неизвестны.

От CE адаптера все методы получают 300 updates, lr0,003:

$$\mathcal{L} = \mathcal{L}_{CE} + 0{,}1 D_{KL}(q_\theta \| q_{CE}) - \lambda I(h) \widehat{\mathbb{E}}_{p_\theta}[r]. \quad (6)$$

q — branch/position distribution; его KL ограничивает сверху KL marginal item policy. CE continuation имеет$\lambda = 0$; reward-only убирает CE, сохраняя KL; uniform joint имеет$I = 1$. Gated допускает reward, если все RM согласны о знаке $\mathbb{E}_c[r] - \mathbb{E}_{p_0}[r]$. Критерий не читает logged target. Ожидание по copy точное, по frozen head — 8 MC samples/context. Для этой конечной смеси градиент reward доступен напрямую: это H1 contextual-bandit адаптация, не full-decoder H5 REINFORCE.

Проверены 12 reward trials seed 17, $\lambda \in \{0{,}1; 0{,}5; 2; 8\}$ для трёх семейств. Выбор — максимальный search NDCG среди точек с proxy не ниже CE; выбраны 0,1 для reward-only и 2 для joint/gated. Primary B — gated−CE continuation с одинаковым дополнительным бюджетом. В AdaGRPO [6] допуск зависит от рангов

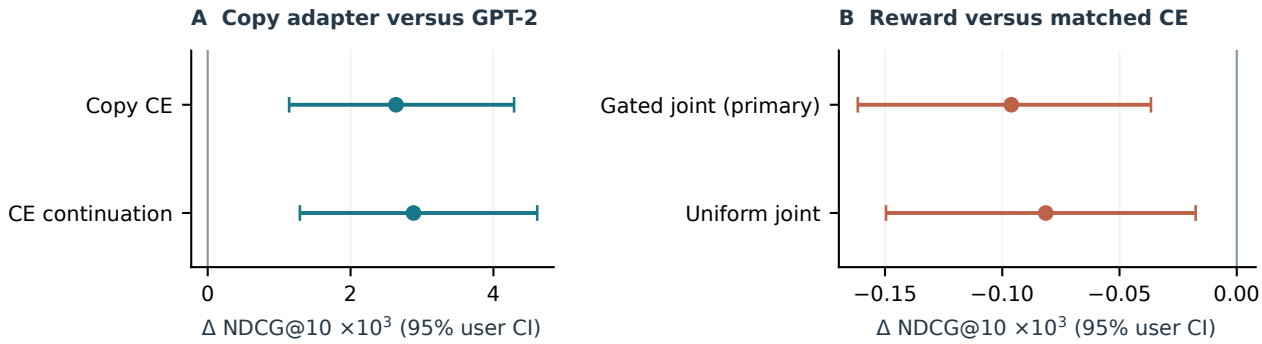


Рис. 3. Test B: улучшение supervised baseline и эффект reward разделены. Слева — copy против GPT-2; справа — reward против matched CE. Масштабы осей различаются. Primary — gated joint. Интервалы контрольных сравнений описательные. Точки A и B не объединяются в одну статистическую проверку.

Таблица 2. Внешний test B: 637 активных UID, 6393 запросов. Сравнивать абсолютные значения между таблицами A/B как эффект метода нельзя.

Метод	NDCG@10	Recall@10	MAP@10
Popularity	0.003370	0.007510	0.002099
Repeat / head	0.008787	0.014725	0.006964
Repeat / full	0.011983	0.020471	0.009352
GPT-2	0.010095	0.020913	0.006888
Copy 50/50	0.011837	0.020592	0.009148
Copy CE	0.012731	0.025023	0.009081
CE continuation	0.012977	0.025332	0.009291
Reward-only	0.012718	0.025030	0.009063
Joint	0.012895	0.025307	0.009199
Gated joint	0.012880	0.025267	0.009192

target/distractors; наш target-free критерий не является воспроизведением этого алгоритма.

5 Проверка на новой когорте

CE continuation получил 0,012977 против 0,010095 у GPT-2: +28.5%, абсолютный прирост 0,002882, CI$[0{,}001290; 0{,}004613]$. Copy CE до продолжения — 0,012731. Превосходство над repeat не установлено: разность 0,000994, CI$[-0{,}001616; 0{,}003283]$. Поэтому результат не объявляется победой над всеми сильными простыми методами.

Primary B отрицателен: gated−CE -0.000096, CI$[-0.000162; -0.000037]$, около$-0{,}74\%$. Снижение мало, но интервал исключает 0. Uniform joint также немного уступает CE: $-0{,}000081$, CI$[-0{,}000150; -0{,}000018]$. Gated пропускает 88,5% train contexts и мало отличается от uniform. Proxy top1 при этом растёт с 0,618404 до 0,618582; это прогноз, не измеренный эффект рекомендации.

На тех же запросах B старая neural RM имеет MSE 0,184392, новая — 0,059784, константа — 0,176966. Снижение относительно константы 66,2%; CI разности$[-0{,}124936; -0{,}109805]$. Но state-only RM, вообще без кандидата, уже имеет MSE 0,063096: она даёт примерно 97% сокращения MSE полного ансамбля относительно константы. Full лучше: CI разности$[-0{,}004046; -0{,}002591]$, при различии бюджета. Одна full RM seed 17 также сильна, MSE 0,059975. Ошибки трёх full RM коррелируют около 0,998 (рис.4).

Предсказуемость состояния пользователя даёт низкую общую MSE, но не обязательно полезное различие между действиями. Это согласуется с риском reward overoptimization [7], хотя не доказывает единственную причину снижения NDCG. Новая RM использует более богатую информацию: её сравнение со старой сетью не изолирует архитектуру. Popularity имеет proxy 0,648050 при NDCG 0,003370: максимум RM и next-item релевантность явно расходятся.

В описательном post-test аудите длительность top1 пересчитана по метаданным, известным к train cutoff 270: CE189,2c, gated189,1c. Ранний duration200 кэш имел unknown=0 (13,2% top1 CE в user-macro), что занижало среднее. Исходный кэш сохранён; policy, reward и первичные метрики не менялись.

6 Воспроизводимость и выводы

Код проверяет сохранение всех исходных строк выбранных UID, отсутствие пересечений когорт, временные границы и неизменность входов при замене будущего. В A выполнен точный replay24 neural top10 forecasts. В обоих циклах forecasts запечатаны до labels. Компактные evidence содержат raw top10, per-user/query метрики, все seeds/trials, RM predictions, rollouts и цепочку SHA. Проверка без датасетов/GPU заново считает числа, а не только сверяет готовый JSON. Тест подмены NDCG при обновлённом checksum отвергается.

Цикл A:48 завершённых fits с пилотом,573c суммарных записанных fit stages; CUDA peak 589,5MiB, max RSS *на конец fit*1656MiB, не peak RSS. Цикл B:24 fits адаптера,4 RM search fits и 2 диагностические RM; записано 30,5c адаптеров,27,2c кэшей и 6,3c основного RM поиска. Оборудование: i7-14700KF,48GB RAM, RTX4070TiSUPER16GB. Это измерения отдельных этапов, не полный wall time исследования: подготовка, сбои, часть диагностик и ручная работа не включены. B переиспользует три SFT, поэтому его числа не показывают цену обучения политики с нуля. Полные журналы сохраняют также неудачные варианты.

Ограничения: один сервис и период, ограниченная поддержка каталога, короткий контекст, неизвестные задержки outcomes и небольшой бюджет HPO. Модели B не обучались на новых UID, но их реальная история доступна в момент запроса. Нельзя переносить эффект

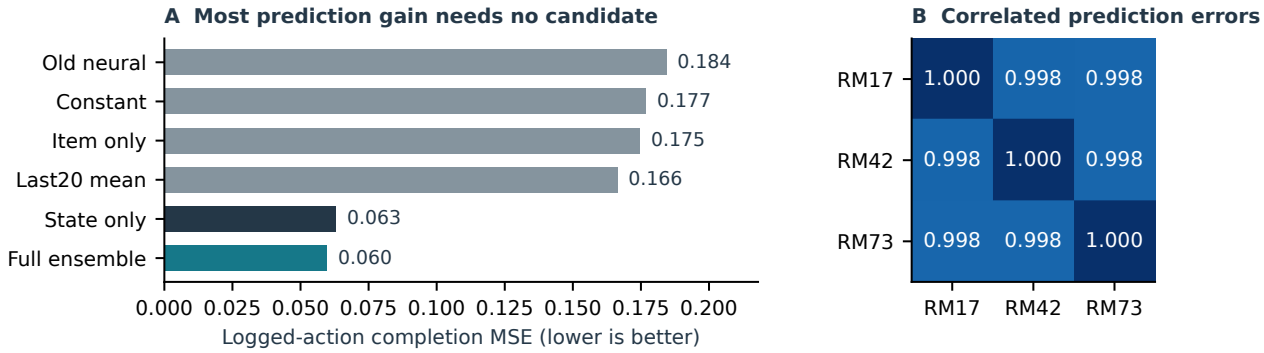


Рис. 4. Test B: старая и новая RM оценены на одних logged actions. State-only — одна модель, full — ансамбль трёх; это не идеально уравненная абляция ансамблей. Справа — корреляция ошибок full RM. Согласие близких моделей не является независимым свидетельством правильности.

16-параметрического H1 адаптера на full-decoder H5 RL. Нет propensities, контрфактуальных labels, IPS/DR оценки или online A/B. Activity не измеряет causal retention, completion не равен удовлетворённости. Все tests теперь открыты; следующий подтверждающий вывод требует новой внешней проверки.

Вывод. Усиление supervised policy и модели отклика дало воспроизводимый прирост соответствующих метрик. Ни штраф за вымышленную историю, ни допуск по согласию RM не подтвердили пользу RL; во втором случае измерено небольшое ухудшение. Для следующих работ недостаточно уменьшать общую MSE: нужно проверять способность RM различать действия и независимость ошибок, а качество рекомендаций подтверждать отдельно от proxy reward.

Материалы.
Главный файл: `article.pdf`. Исходник: `code/paper/submission_task2/article.tex`.
Результаты: `code/reports/task2/`, `code/reports/task2b/`.
Из `code/`: `uv sync --locked --extra dev`, затем `uv run --locked python scripts/verify_submission.py`.

Список литературы

[1] Petrov, Macdonald. Aligning GPTRec with Beyond-Accuracy Goals with Reinforcement Learning. 2024. arXiv:2403.04875.

[2] Matveev et al. Session-Level Optimization for Large-Scale Retrieval using REINFORCE with Multi-Step Off-Policy Correction. 2026. arXiv:2607.02818v2.

[3] Coste et al. Reward Model Ensembles Help Mitigate Overoptimization. ICLR 2024. arXiv:2310.02743.

[4] Merity et al. Pointer Sentinel Mixture Models. ICLR 2017. arXiv:1609.07843.

[5] Ren et al. RepeatNet: A Repeat Aware Neural Recommendation Machine for Session-based Recommendation. AAAI 2019. arXiv:1812.02646.

[6] Xu et al. Adaptive Loss Balancing for Noise-Robust GRPO in Generative Recommendation. Препринт 2026. arXiv:2606.08480.

[7] Gao, Schulman, Hilton. Scaling Laws for Reward Model Overoptimization. 2022. arXiv:2210.10760.