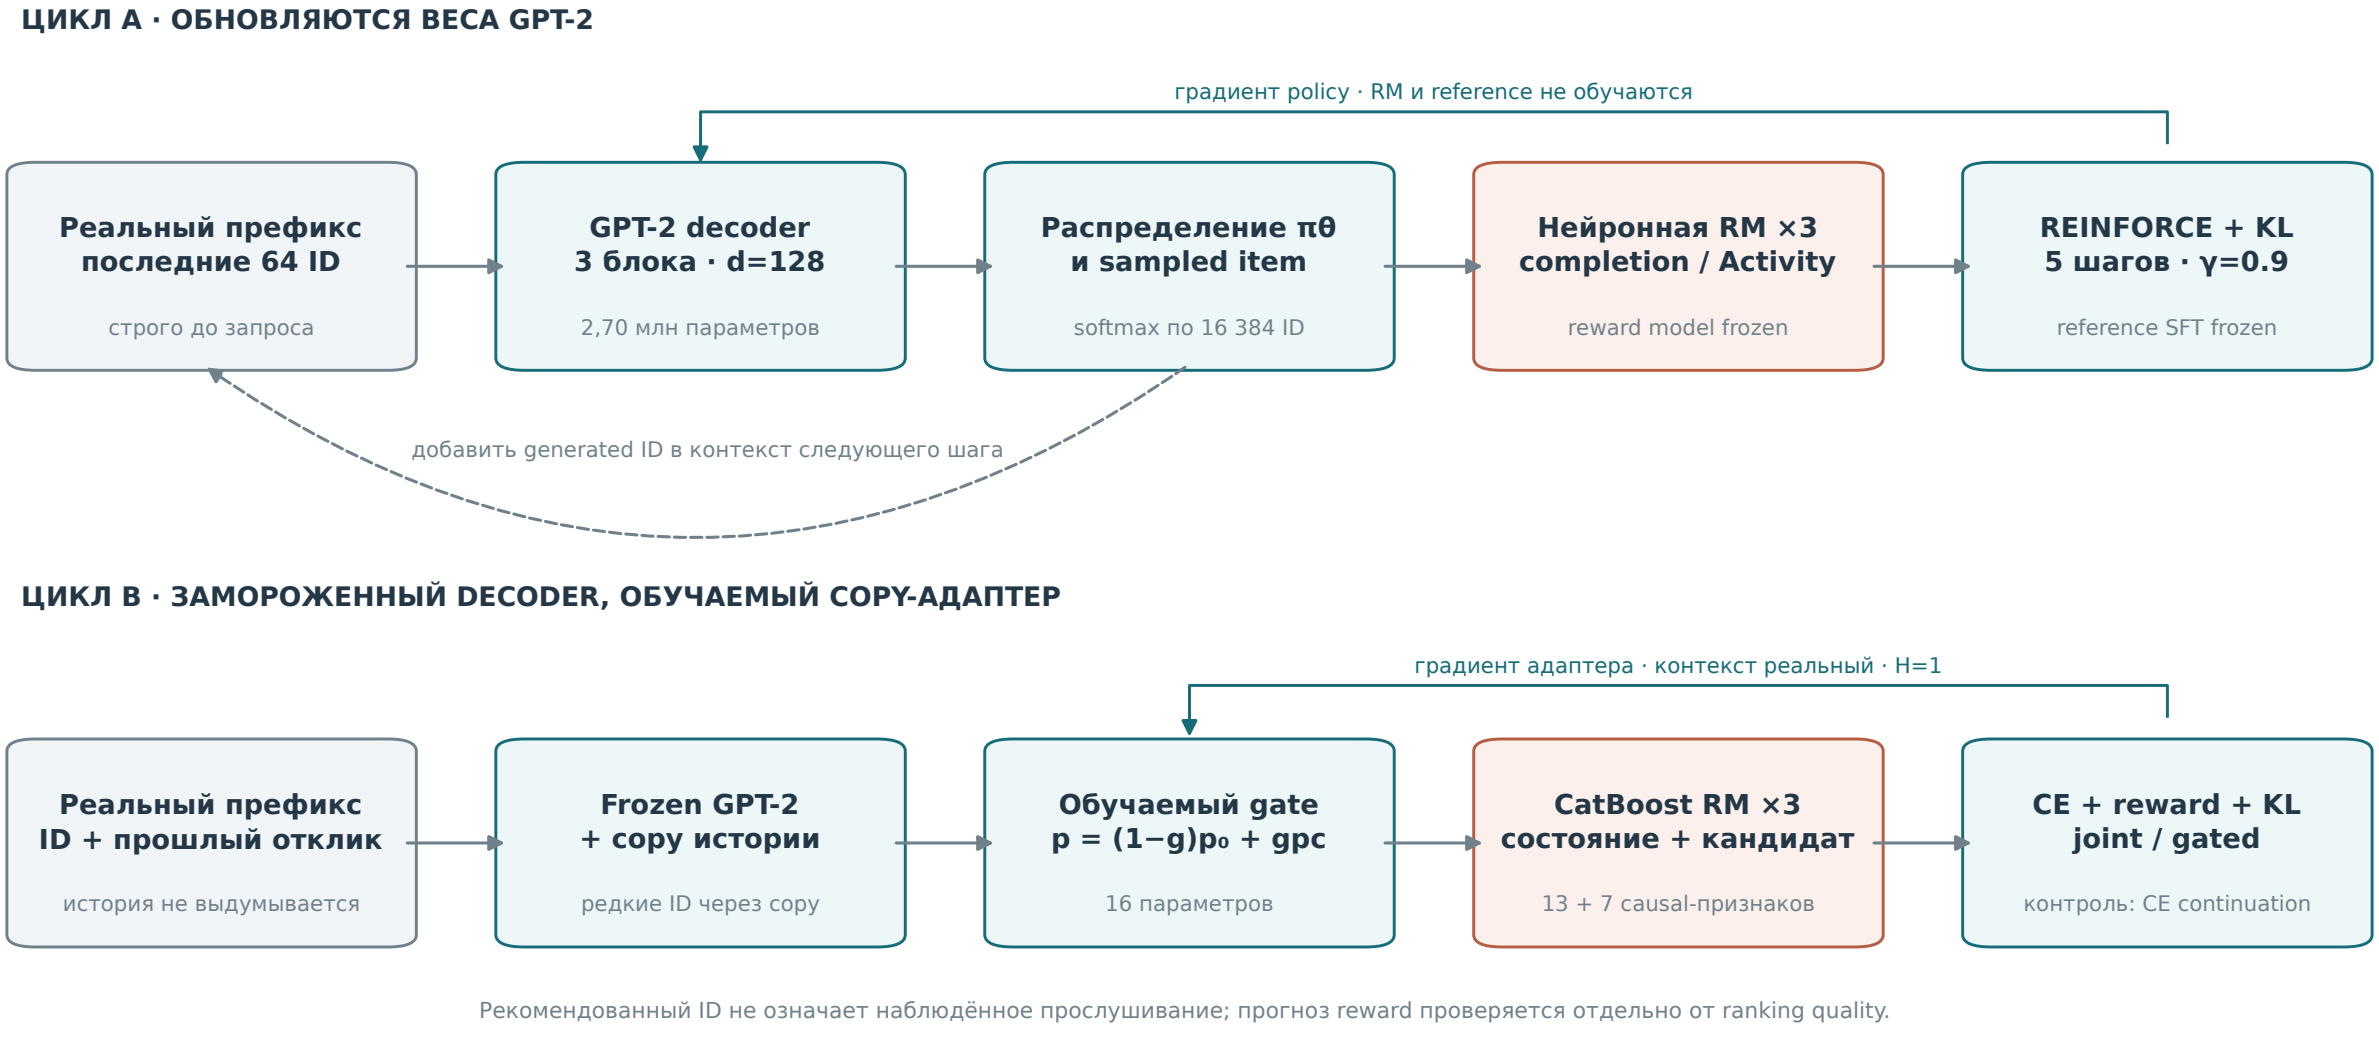
ЦИКЛ A · ОБНОВЛЯЮТСЯ ВЕСА GPT-2
градиент policy · RM и reference не обучаются
Реальный префикс
последние 64 ID
строго до запроса
GPT-2 decoder
3 блока · d=128
2,70 млн параметров
Распределение πθ
и sampled item
softmax по 16 384 ID
Нейронная RM ×3
completion / Activity
reward model frozen
REINFORCE + KL
5 шагов · γ=0.9
reference SFT frozen
добавить generated ID в контекст следующего шага
ЦИКЛ B · ЗАМОРОЖЕННЫЙ DECODER, ОБУЧАЕМЫЙ COPY-АДАПТЕР
градиент адаптера · контекст реальный · H=1
Реальный префикс
ID + прошлый отклик
история не выдумывается
Frozen GPT-2
+ copy истории
редкие ID через copy
Обучаемый gate
p = (1−g)p₀ + gpc
16 параметров
CatBoost RM ×3
состояние + кандидат
13 + 7 causal-признаков
CE + reward + KL
joint / gated
контроль: CE continuation
Рекомендованный ID не означает наблюдённое прослушивание; прогноз reward проверяется отдельно от ranking quality.