Оптимизация выученной награды в последовательных рекомендациях

GPT-2, пять шагов генерации и контроль вымышленной истории

Воспроизводимое исследование на Yambda 50M / Октябрь 2026

Аннотация. Можно ли повысить предсказанную награду рекомендаций, сохранив их точность? Мы обучили GPT-2 на идентификаторах треков и дообучили её с помощью REINFORCE по модели отклика. Исследованы пять наград и три силы KL-штрафа. В отдельной когорте из 266 активных пользователей ансамблевая награда повысила оценку доли прослушивания с 0.7143 до 0.7242, но прирост NDCG@10 не подтверждён. Предложенный штраф за расхождение оценки в реальной и дополненной истории также не дал убедительного выигрыша: $\Delta = -0.000037$, 95% интервал $[-0.000571; +0.000497]$. Пятишаговый аудит показывает, как добавление собственных рекомендаций в контекст повышает оценку reward model без наблюдения пользовательской реакции.

1 Проблема и проверяемая идея

Последовательная модель воспроизводит следующее действие из лога. RL меняет цель, например на долю прослушивания или последующую активность. Настоящий отклик на новый выбор неизвестен: оптимизатор может улучшать прогноз модели отклика, а не пользовательский опыт.

При генерации пяти треков каждый выбранный ID добавляется в контекст. Но рекомендация ещё не означает прослушивание. RM оценивает кандидата по истории, содержащей неподтверждённые действия.

Мы оцениваем один кандидат в дополненной истории h_t и исходной реальной истории h_0, затем штрафуем расхождение. Контроль с той же ансамблевой наградой изолирует добавленный штраф. Это экспериментальная гипотеза без заявления мирового приоритета или теоретической гарантии.

2 Данные и честная оценка

Использована таблица `listens` Yambda 50M, pinned revision из репозитория. Из пользователей двух предыдущих исследований исключены все UID; затем равномерно выбраны 1200 новых пользователей. Сохранены все 5 736 029 исходных строк выбранных UID, включая короткие прослушивания и органические действия. Sampling seed 718281; разбиение UID на development 800 / external 400 зафиксировано до обучения.

Время анонимизировано: сутки равны 86 400 секундам. Модели обучаются на событиях до day 270; подбор настроек использует days280–286 только development UID. Внешняя оценка проводится на days293–298 только external UID. Их ранние истории участвуют в обучении, но поздние метки не выбирают настройки. Это временной holdout с другой когортой оценки, а не cold-user задача или независимая будущая репликация: период частично совпадает с первой работой, пользователи не пересекаются.

Каждый запрос предсказывает один следующий неорганический listen. Оцениваются первые до четырёх событий с уникальным timestamp за user-day. Нет отбора по доле прослушивания. История содержит только события строго раньше запроса. Переходы между строками с одинаковым timestamp не входят в supervised loss; их искусственный порядок не считается известной последовательностью действий.

Каталог всех методов одинаков: 16 384 самых частых train items. Повторы разрешены. Будущая цель не добавляется в каталог. По числу запросов вне словаря осталось 47.4% внешних целей; они остаются промахами в знаменателях. Это существенное ограничение бюджета, а не только cold-start: вне словаря бывают и редкие старые треки. Максимально возможный user-macro Recall для этого каталога равен 0.5433. Истории сохраняются полностью; модельный контекст ограничен последними 64 ID, неизвестные ID кодируются UNK.

На внешнем периоде получены 2770 запроса от 266 активных тёплых пользователей. NDCG, Recall и MAP при $K = 10$ сначала усредняются по трём model seeds для запроса, затем по запросам внутри пользователя и по пользователям. Интервалы разностей получены парным bootstrap целых пользователей, 3000 resamples. Они условны на этих данных и fits; не покрывают другие периоды и весь риск выбора настроек.

3 Модели и обучение

3.1 GPT-2 и простые контроли

Используется уменьшенная архитектура GPT-2 с нуля: learned item и position embeddings, три pre-LN causal decoder блока, размерность 128, четыре heads, GELU, MLP expansion4, final LayerNorm и общий вес input/output embeddings. Всего 2.70 млн параметров. Это модель над item IDs; текстовые pretrained weights не используются. Полная softmax рассчитывается по всему каталогу. Исходную обученную модель обозначаем SFT.

Первоначальный бюджет 1500 updates дал development NDCG 0.00958. До открытия внешнего теста он был увеличен до 12 000: лучший checkpoint на development оказался на 3000 updates, NDCG 0.01453. Дальнейшее снижение train loss не улучшило ranking. Поправка протокола, полная траектория и девять пилотных RL fits сохранены.

AdamW: lr$= 3 \cdot 10^{-4}$, weight decay 0.01, warmup 300, cosine schedule до 12 000, effective batch 64. Seeds 17/42/73 получают одинаковые 3000 выбранных updates; seed 17 также несёт цену полного checkpoint search. Контроли используют тот же каталог: train

popularity, повторное потребление по доступному контексту, Markov первого порядка со сглаживанием popularity. Дополнительный CE fit на 120 updates проверяет пользу продолжения supervised обучения; он не является joint NLL+RL baseline.

3.2 Модель отклика

RM получает историю ID и ID кандидата. Отдельные embeddings позволяют вычислить mean/last history pooling и взаимодействие истории с кандидатом; к MLP добавлена статическая длительность из train. Текущий played ratio не входит во вход модели. Две sigmoid heads предсказывают: (1) $y = \min(1, \texttt{played_ratio_pct}/100)$; (2) наличие события в $[t + 1\text{h}, t + 24\text{h})$. Второй сигнал обозначаем *Activity*. Он описывает последующую активность, включая продолжающееся потребление, а не доказанный возврат после ухода из сервиса.

RM обучается только на реально наблюдавшихся неорганических listens до day 269: её 24h label horizon целиком заканчивается до day 270. Неизвестные отклики на непрослушанные кандидаты не размечаются нулями. До 1500 train examples на пользователя, всего 855 792; batch 512, lr= 10^{-3}, 800 updates, fractional/binary BCE. Три RM с seeds 17/42/73 образуют ансамбль. Четвёртая, audit RM seed 101, не участвует в reward; она имеет другую инициализацию, но те же данные и архитектуру. Она не является независимой разметкой или oracle.

3.3 Награда и policy gradient

Пусть $m(h, a)$ и $s(h, a)$ — среднее и population std трёх ratio heads. Сравниваются пять наград: Ratio (одна RM), Seconds ($\hat{y}\min(d, 600)/600$), Activity ($0.5\hat{y} + 0.5\hat{p}_{24}$), а также два контролируемых варианта:

$$r_E(h_t, a) = m(h_t, a) - 0.5s(h_t, a), \quad (1)$$

$$r_A(h_t, a) = r_E(h_t, a) - |m(h_t, a) - m(h_0, a)|. \quad (2)$$

Разброс ансамбля не считается калиброванной неопределённостью. Последний штраф нулевой на первом шаге. Он может подавлять и полезный контекстный сдвиг, поэтому его эффект требует проверки.

REINFORCE запускается *on-policy внутри выученного surrogate*, не в настоящей пользовательской среде. Каждый rollout начинается с реального train prefix, пользователь выбирается равномерно. Пять раз сэмплируется ID из полной softmax; ID добавляется в контекст, выдуманные playback labels не добавляются. Награда регуляризуется относительно замороженной SFT policy π_0:

$$\widetilde{r}_t = r_t - \beta \log \frac{\pi_\theta(a_t \mid h_t)}{\pi_0(a_t \mid h_t)}, \quad (3)$$

$$G_t = \sum_{j=t}^{H-1} \gamma^{j-t} \widetilde{r}_j. \quad (4)$$

Градиент использует $\gamma^t(G_t - b_t)\nabla \log \pi_\theta(a_t \mid h_t)$; baseline b_t — среднее return других независимых trajectories batch. Dropout у policy выключен. AdamW lr= $5 \cdot 10^{-5}$, $\gamma = 0.9$, batch 96, 120 updates, grad clip1.

На development проверены $5 \times 3 = 15$ конфигураций, $\beta \in \{0.02, 0.1, 0.5\}$. В каждой семье выбиралась наибольшая предсказанная доля среди точек с NDCG не ниже 95% SFT. Это правило выбора, а не статистическое доказательство non-inferiority. Выбраны $\beta = 0.1$ для Ratio/Ensemble/Anchored и 0.5 для Seconds/Activity. Главное заранее заданное сравнение — Anchored−Ensemble при одинаковом $\beta = 0.1$. Контроль $H = 1$ имеет те же 120 updates, но в пять раз меньше sampled actions: это ограничение его интерпретации.

Таблица 1. Внешнее качество следующего logged item. Среднее отдельных fits seeds 17/42/73, а не ансамбль policy. Лучший простой контроль обязателен для интерпретации; point estimate не равен значимому выигрышу.

Метод	NDCG@10	Recall@10	MAP@10
Popularity	0.00198	0.00486	0.00111
Markov	0.00638	0.01153	0.00485
Repeat	0.01153	0.01867	0.00938
GPT-2 / CE	0.01097	0.02134	0.00794
+ CE	0.01131	0.02189	0.00820
Ratio	0.01102	0.02092	0.00807
Seconds	0.01102	0.02154	0.00797
Activity	0.01085	0.02063	0.00797
Ensemble H=1	0.01072	0.02115	0.00767
Ensemble	0.01117	0.02167	0.00804
Anchored	0.01113	0.02067	0.00828

4 Результаты и причины

4.1 Релевантность и цена награды

Внешняя SFT получила NDCG 0.01097, Repeat — 0.01153. Разность Repeat−SFT 0.00057 имеет интервал $[-0.00305; 0.00446]$: превосходство простого контроля также не установлено. Абсолютные числа нельзя сравнивать с первой задачей: там предсказывалось множество треков за сутки, здесь — одно следующее действие.

Ensemble повышает предсказанную ratio top1 с 0.7143 до 0.7242. NDCG растёт лишь на 0.00020, CI$[-0.00105; 0.00138]$. Все выбранные RL-варианты имеют интервалы к SFT, включающие ноль (рис. 1). Доказательств улучшения реальной релевантности нет. Разброс seed заметен: для Ensemble NDCG составляет 0.01248/0.01025/0.01077.

Основной контраст Anchored−Ensemble: -0.000037, CI$[-0.000571; +0.000497]$. Штраф не подтвердил преимущество. Он уменьшил среднюю exact KL с 0.1145 до 0.0979, но само по себе меньшее отклонение от SFT не является улучшением рекомендаций.

Смена награды меняет состав выдачи предсказуемым способом. Ratio рекомендует в среднем 182 секунды против 192 у SFT; Seconds —199 секунд. На development слабый KL у Seconds ($\beta = 0.02$) увеличил среднюю длительность до 390 секунд, один трек занял 51.3% top1, NDCG упала до 0.00193. Эта точка не выбрана и не выдаётся за внешний результат. В выбранных внешних точках такого коллапса нет: самый частый top1 занимает около 1–2% запросов.

4.2 Насколько надёжна RM

Таблица 2 показывает метрики на всех внешних logged actions, включая цели вне каталога. MSE/MAE здесь усредняются по событиям; их bootstrap сохраняет кластеры пользователей. Ансамбль едва превосходит посто-

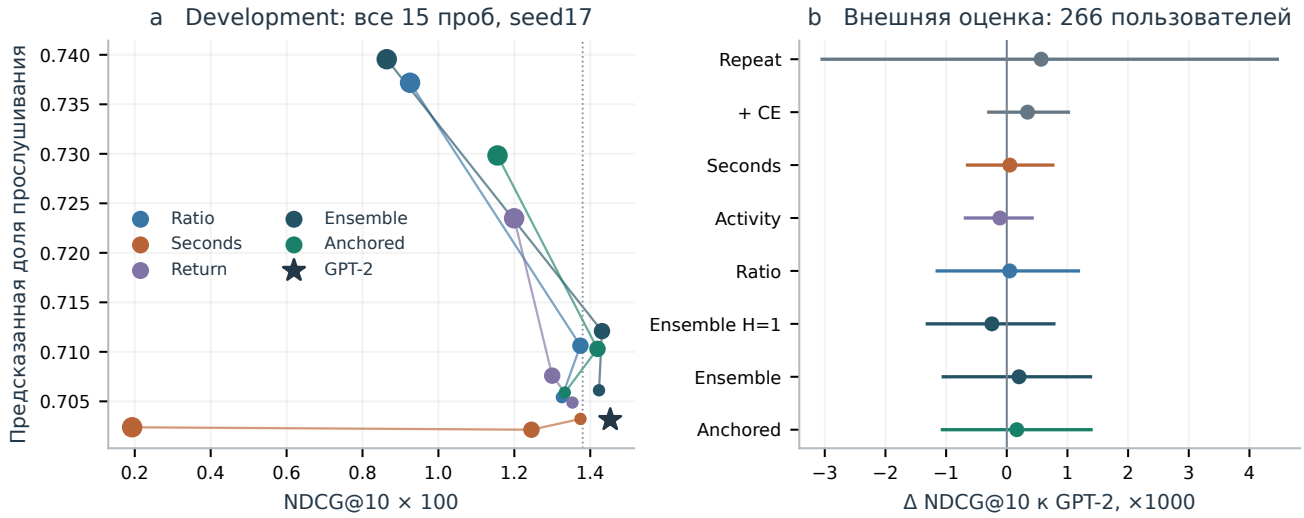


Рис. 1. Слева — полный development search. Общая вертикальная ось показывает ratio RM и для политик с другими rewards; размер точки растёт при уменьшении β (0.5,0.1,0.02). Пунктир — правило 95% SFT. Справа — внешние разности с SFT и описательные 95% user-cluster CI. Ни один RL-вариант не подтвердил прирост NDCG. Это не доказательство эквивалентности.

Таблица 2. RM на 2770 реально наблюдавшихся действиях. Ratio MSE/MAE; AUC и Brier относятся к Activity. «Чужая история» — диагностическая подмена контекста при неизменном кандидате, а не новая обученная модель.

Модель	MSE	MAE	AUC	Brier
Global mean	0.1806	0.3777	0.500	0.1359
Item mean	0.1813	0.3743	0.525	0.1363
Ensemble RM	0.1798	0.3496	0.568	0.1379
Audit RM	0.1834	0.3521	0.581	0.1396
Чужая история	0.2056	0.3801	0.488	0.1453

янное среднее по ratio MSE: 0.1798 против 0.1806; по индивидуальным RM ошибка хуже. Надёжное улучшение MSE не подтверждено (рис. 2,b). При этом MAE ниже, а подмена пользовательской истории чужой доступной историей повышает MSE до 0.2056. Следовательно, модель использует соответствие контекста пользователю, но это не обеспечивает точность всех условных прогнозов.

Activity AUC ансамбля 0.568 показывает слабое различение будущей активности. Её Brier 0.1379 хуже константы 0.1359. Увеличение такого reward нельзя интерпретировать как улучшение удержания. Согласие audit RM с оптимизируемой RM также не заменяет контрфактуальную разметку: общие данные создают общие ошибки.

4.3 Пять шагов и вымышленная история

Для 256 пользователей взят один реальный начальный prefix. Каждая policy генерирует пять actions, отдельно с обновлением контекста и с замороженной историей. Sampling seeds связаны: первый action в двух режимах совпадает. Значения на рис. 3 описательные, без выбора новых настроек.

В режиме обновления история сама повышает прогноз ratio Ensemble примерно с 0.717 до 0.737. При замороженной истории оценка остаётся около 0.718. Но никакой реакции на выбранные треки не наблюдалось. К пятому шагу средняя абсолютная разница RM для одного action в дополненном и первоначальном контексте достигает около 0.05. Anchored не уменьшил этот сдвиг убедительно; его кривая близка к Ensemble. Повторы внутри списка составляют несколько процентов, а не объясняют весь рост proxy.

Отдельная teacher-forced проверка использует следующие реальные actions и настоящие prefixes, а не сгенерированные ID. Число доступных пользователей уменьшается по шагам; это сохранено в evidence. Уже на первом запросе каждого пользователя ratio MSE 0.244, хотя по всей внешней выборке 0.180. У generated actions истинной MSE нет: сравнение их reward с observed trajectory не оценивает причинный эффект.

5 Связь с литературой и ограничения

GPTRec [2] использует Next-K генерацию, teacher–student и PPO; здесь обучается next-item GPT-2 [1] и RM отклика. В отличие от off-policy REINFORCE на Yambda-5B [3], нет известных logging propensities и оценок IPS/DR. Наши model-based средние не являются unbiased policy value; цели вне словаря не добавляются в каталог оценки.

Риск overoptimization [4] и консервативные ансамбли RM [5] известны. Наш вклад — отдельная проверка контекстного штрафа с matched-beta контролем, вместе с диагностикой реальной и вымышленной истории. Теоретические гарантии MOPO [6] на него не переносятся: пользовательская transition dynamics не обучается. AdaGRPO [7] мотивирует селективное доверие noisy rewards; её NLL+GRPO gate здесь не реализован. Это важный недостающий сильный контроль.

Основные ограничения: 1200 пользователей активной популяции, один период, малый словарь и слабая RM после временного разрыва. Append-ID surrogate не описывает решение пропустить трек, уйти или вернуться. Три seeds не заменяют новые данные и online A/B. Продолжение требует нового внешнего периода, калибровки RM по типам контекста и модели переходов с наблюдаемым feedback; текущий test уже открыт.

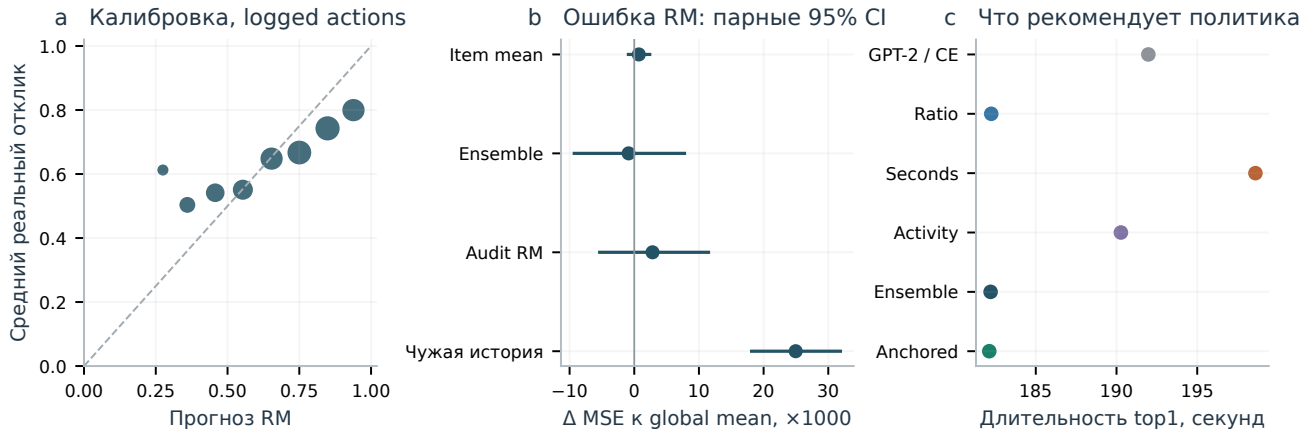


Рис. 2. Аудит RM и политики. В калибровке размер точки пропорционален корню из числа примеров bin; bins с менее 10 событиями не показаны. Интервалы MSE получены resampling пользователей с сохранением взвешивания по событиям. Справа — длительность рекомендованного top1, среднее по пользователям и seeds; это не фактическое время прослушивания.

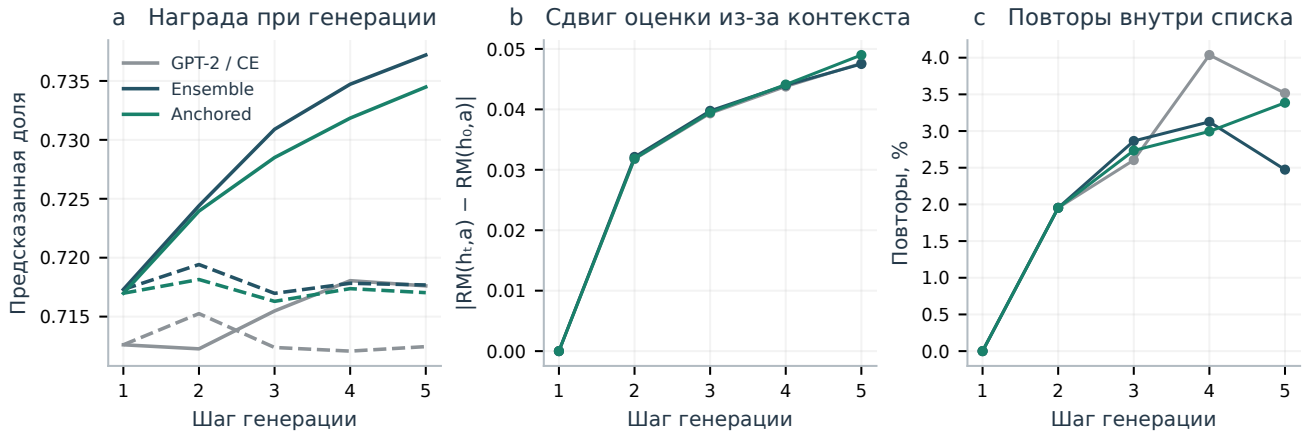


Рис. 3. Пятишаговый model-based аудит,256 пользователей, три policy seeds. Сплошные линии — generated ID добавляются в историю; пунктир слева — та же policy с замороженной историей. Середина сравнивает один и тот же выбранный action в двух контекстах. Правый график — вероятность повторить ранее выбранный в этом списке ID. Отклики пользователей в этом эксперименте не симулируются как реальные события.

6 Вывод и воспроизводимость

RL действительно меняет выдачу и повышает выученную proxy-награду. В данном эксперименте это не дало подтверждённого выигрыша next-item релевантности. Предложенная защита от вымышленной истории также не подтвердила преимущество. Результат — измеренное расхождение между оптимизацией RM, точностью по логам и оценкой на дополненном контексте.

Код, два протокола, полный search, отдельные seeds, сырые top10 forecasts и компактные доказательства находятся в репозитории. Все 24 нейронных массива top10 воспроизведены точно;64 проверки замены будущих items не изменили исторический context; проверено сохранение всех исходных строк выбранных UID. Зафиксированы 48 завершённых fits, включая пилот; сумма записанных fit durations —9.6 минут на RTX4070TiSUPER. Это не полное время исследования или изолированный benchmark.

Метрики проверяются без Yambda и GPU. Инструкции полного запуска и проверки —в `TASK2_REPRODUCE.md` репозитория.

Список литературы

[1] Radford et al. Language Models are Unsupervised Multitask Learners. 2019. Architecture/code.
[2] Petrov, Macdonald. Aligning GPTRec with Beyond-Accuracy Goals with Reinforcement Learning. GenRec, 2024. arXiv:2403.04875.
[3] Matveev et al. Session-Level Optimization for Large-Scale Retrieval using REINFORCE with Multi-Step Off-Policy Correction. 2026. arXiv:2607.02818v2.
[4] Gao, Schulman, Hilton. Scaling Laws for Reward Model Overoptimization. 2022. arXiv:2210.10760.
[5] Coste et al. Reward Model Ensembles Help Mitigate Overoptimization. ICLR, 2024. arXiv:2310.02743.
[6] Yu et al. MOPO: Model-based Offline Policy Optimization. NeurIPS, 2020. arXiv:2005.13239.
[7] Xu et al. Adaptive Loss Balancing for Noise-Robust GRPO in Generative Recommendation. 2026, preprint. arXiv:2606.08480.