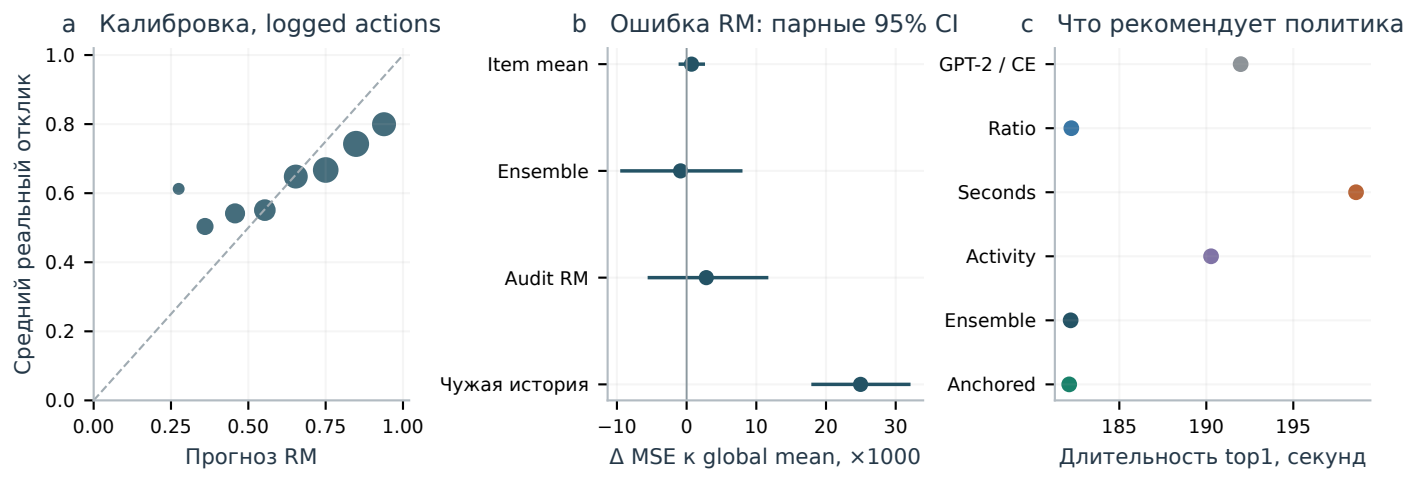
a Калибровка, logged actions
Средний реальный отклик
Прогноз RM
0.0
0.2
0.4
0.6
0.8
1.0
0.00
0.25
0.50
0.75
1.00
b Ошибка RM: парные 95% CI
Item mean
Ensemble
Audit RM
Чужая история
−10
0
10
20
30
Δ MSE к global mean, ×1000
c Что рекомендует политика
GPT-2 / CE
Ratio
Seconds
Activity
Ensemble
Anchored
185
190
195
Длительность top1, секунд